

Perbandingan Kinerja Convolutional Neural Network (CNN) From Scratch dan Transfer Learning MobileNetV2 pada Klasifikasi Citra

Assyifa Nailah Abdullah

Universitas Darussalam Gontor

Teknik Informatika

assyifanailahabdullah76@student.cs.unida.gontor.ac.id

Abstrak

asifikasi citra merupakan salah satu penerapan deep learning yang banyak digunakan dalam berbagai bidang. Dua pendekatan yang umum digunakan untuk klasifikasi citra adalah Convolutional Neural Network (CNN) yang dibangun dari awal (*from scratch*) dan Transfer Learning yang memanfaatkan model *pretrained*. Penelitian ini bertujuan untuk membandingkan performa CNN From Scratch dan Transfer Learning menggunakan MobileNetV2 pada tugas klasifikasi citra. Model CNN dilatih menggunakan dataset CIFAR-10, sedangkan model Transfer Learning memanfaatkan MobileNetV2 sebagai ekstraktor fitur yang telah dilatih sebelumnya. Evaluasi dilakukan berdasarkan akurasi training, akurasi validasi, akurasi testing, nilai loss, serta waktu pelatihan. Hasil eksperimen menunjukkan bahwa CNN From Scratch memperoleh akurasi testing sebesar **70,00%**, sedangkan Transfer Learning memperoleh akurasi testing sebesar **66,50%**. Meskipun CNN From Scratch menghasilkan akurasi yang lebih tinggi, Transfer Learning menawarkan proses pelatihan yang lebih cepat dan implementasi yang lebih sederhana. Oleh karena itu, pemilihan metode yang tepat perlu mempertimbangkan ukuran dataset, sumber daya komputasi, waktu pengembangan, dan kebutuhan aplikasi.

Kata Kunci—Deep Learning, CNN, Transfer Learning, MobileNetV2, Klasifikasi Citra.

I. Pendahuluan

Klasifikasi citra merupakan salah satu penerapan Deep Learning yang banyak digunakan dalam berbagai bidang, seperti pengenalan objek, diagnosis medis, sistem keamanan, dan kendaraan otonom. Tujuan dari klasifikasi citra adalah mengelompokkan gambar ke dalam kategori tertentu berdasarkan karakteristik visual yang dimiliki.

Salah satu metode yang sering digunakan untuk klasifikasi citra adalah **Convolutional Neural Network (CNN)**. CNN mampu mengekstraksi fitur citra secara otomatis dan menghasilkan performa yang baik. Namun, pelatihan CNN dari awal (*from scratch*) membutuhkan jumlah data yang besar serta waktu pelatihan yang relatif lama.

Sebagai alternatif, Transfer Learning memanfaatkan model yang telah dilatih sebelumnya (*pretrained model*) sehingga dapat mengurangi waktu pelatihan dan kebutuhan data. Pendekatan ini banyak digunakan ketika jumlah data terbatas atau sumber daya komputasi tidak memadai.

Pada penelitian ini dilakukan perbandingan antara CNN From Scratch dan Transfer Learning menggunakan MobileNetV2 untuk klasifikasi citra. Perbandingan dilakukan berdasarkan akurasi, loss, waktu pelatihan, dan kemampuan model dalam melakukan klasifikasi. Hasil penelitian diharapkan dapat membantu menentukan pendekatan yang lebih sesuai berdasarkan karakteristik dataset dan kebutuhan aplikasi.

II. Dataset dan Preprocessing

A. Dataset

Pada penelitian ini digunakan dataset CIFAR-10 sebagai dataset utama untuk eksperimen klasifikasi citra. CIFAR-10 merupakan dataset yang terdiri dari 60.000 gambar berwarna berukuran 32×32 piksel yang terbagi ke dalam 10 kelas objek, yaitu airplane, automobile, bird, cat, deer, dog, frog, horse, ship, dan truck.

Pada eksperimen CNN From Scratch digunakan seluruh kelas pada dataset CIFAR-10. Sementara itu, pada eksperimen Transfer Learning digunakan dua kelas, yaitu cat dan dog, sehingga membentuk permasalahan klasifikasi biner.

B. Pembagian Data

Dataset dibagi menjadi data training, validation, dan testing. Pada eksperimen CNN From Scratch digunakan data training dengan validation split sebesar 20%, sedangkan evaluasi akhir dilakukan menggunakan data testing. Pembagian ini bertujuan agar model dapat dilatih dan dievaluasi secara objektif.

C. Preprocessing Data

Sebelum proses pelatihan model, dilakukan beberapa tahapan preprocessing data, yaitu:

1. Normalisasi Data

Nilai piksel citra diubah ke rentang 0–1 dengan membagi setiap nilai piksel dengan 255.

2. Resizing Citra

Pada eksperimen Transfer Learning, ukuran citra diubah menjadi 96×96 piksel agar sesuai dengan kebutuhan input model MobileNetV2.

3. Pembentukan Dataset Biner

Untuk Transfer Learning dipilih dua kelas, yaitu cat dan dog, sehingga model hanya melakukan klasifikasi terhadap dua kategori tersebut.


III. IMPLEMENTASI CNN FROM SCRATCH

A. Arsitektur Model

Model CNN dibangun dari awal tanpa menggunakan pretrained model. Arsitektur yang digunakan terdiri dari beberapa lapisan konvolusi dan pooling yang berfungsi untuk mengekstraksi fitur citra secara bertahap.

Arsitektur model yang digunakan adalah sebagai berikut:

Layer	Konfigurasi
Conv2D	32filter,3x3,ReLU
MaxPooling2D	2x2
Conv2D	64filter,3x3,ReLU
MaxPooling2D	2x2
Conv2D	64filter,3x3,ReLU
Flatten	-
Dense	64 Neuron, ReLU
Output	10 Neuron, Softmax



B. Alasan Pemilihan Arsitektur

Arsitektur tersebut dipilih karena cukup sederhana dan mampu mengekstraksi fitur citra secara bertingkat. Layer konvolusi digunakan untuk mendeteksi pola visual, sedangkan layer pooling berfungsi mengurangi dimensi data dan kompleksitas komputasi. Layer dense digunakan untuk melakukan proses klasifikasi berdasarkan fitur yang telah dipelajari.

C. Parameter Pelatihan

Parameter yang digunakan pada proses pelatihan adalah sebagai berikut:

Parameter	Nilai
Optimizer	Adam
Epoch	10
Validation Split	20%
Loss Function	Sparse Categorical Crossentropy
Metric	Accuracy

IV. IMPLEMENTASI TRANSFER LEARNING

A. Model Transfer Learning


Pada eksperimen kedua digunakan metode Transfer Learning dengan memanfaatkan model MobileNetV2 yang telah dilatih sebelumnya pada dataset ImageNet. Model ini dipilih karena memiliki ukuran yang ringan, efisien, dan mampu memberikan performa yang baik pada berbagai tugas klasifikasi citra.

B. Strategi Transfer Learning

Strategi yang digunakan adalah Feature Extraction, yaitu dengan membekukan (*freeze*) seluruh layer pada MobileNetV2 dan hanya melatih layer klasifikasi yang ditambahkan pada bagian akhir model.

Arsitektur model terdiri dari:

Layer	Konfigurasi
MobileNetV2	PretainedModel
Global Average Pooling	Feature Extraction
Dense	1 Neuron, Sigmoid



C. Alasan Pemilihan Model

MobileNetV2 dipilih karena memiliki jumlah parameter yang relatif kecil dibandingkan model pretrained lainnya sehingga proses pelatihan menjadi lebih cepat. Selain itu, MobileNetV2 telah terbukti mampu menghasilkan performa yang baik pada berbagai permasalahan klasifikasi citra.

D. Parameter Pelatihan



Parameter	Nilai
Optimizer	Adam
Epoch	10
Batch Size	32
Loss Function	Binary Crossentropy
Metric	Accuracy

V. HASIL DAN PEMBAHASAN


A. Hasil CNN From Scratch

Berdasarkan hasil pelatihan model CNN From Scratch diperoleh hasil sebagai berikut:

Metric	Nilai
Training Accuracy	77.55%
Validation Accuracy	70.66%
Testing Accuracy	70.00%
Training Loss	0.6360
Validation Loss	0.8913




Berdasarkan hasil yang diperoleh, model CNN mampu mencapai akurasi testing sebesar 70.00%. Hal ini menunjukkan bahwa model mampu mempelajari pola dari dataset dengan cukup baik. Namun terdapat perbedaan antara akurasi training dan validation yang mengindikasikan adanya overfitting ringan.



B. Hasil Transfer Learning

Berdasarkan hasil pelatihan model Transfer Learning menggunakan MobileNetV2 diperoleh hasil sebagai berikut:

Metrik	Nilai
Training Accuracy	66.22%
Validation Accuracy	66.95%
Testing Accuracy	66.50%
Training Loss	0.6168
Validation Loss	0.6181



C. Perbandingan Model

Aspek	CNN From Scratch	Transfer Learning
Training Accuracy	77.55%	66.22%
Validation Accuracy	70.66%	66.95%
Testing Accuracy	70.00%	66.50%
Training Loss	0.6360	0.6168
Validation Loss	0.8913	0.6181
Time Training	Lebih Lama	Lebih Cepat
Risiko Overfitting	Lebih Tinggi	Lebih Rendah
Kemudahan Implementasi	Sedang	Mudah

Berdasarkan hasil eksperimen, CNN From Scratch menghasilkan akurasi yang lebih tinggi dibandingkan Transfer Learning. Hal ini menunjukkan bahwa CNN mampu mempelajari karakteristik dataset dengan baik ketika jumlah data yang tersedia cukup banyak. Namun, Transfer Learning memiliki keunggulan dalam hal efisiensi waktu pelatihan dan stabilitas model.

VI. ANALISIS PEMILIHAN PENDEKATAN

A. Kapan Menggunakan CNN From Scratch

CNN From Scratch lebih sesuai digunakan ketika tersedia dataset dalam jumlah besar, sumber daya komputasi yang memadai, serta kebutuhan untuk membangun model yang spesifik terhadap suatu domain tertentu. Dengan

data yang cukup, model dapat mempelajari fitur secara langsung tanpa bergantung pada pengetahuan dari model lain.

B. Kapan Menggunakan Transfer Learning

Transfer Learning lebih cocok digunakan ketika jumlah data terbatas, waktu pengembangan singkat, atau sumber daya komputasi terbatas. Pendekatan ini mampu memanfaatkan pengetahuan yang telah dipelajari sebelumnya sehingga proses pelatihan menjadi lebih efisien.

C. Hasil Analisis

Berdasarkan eksperimen yang dilakukan, CNN From Scratch memberikan akurasi yang lebih tinggi dibandingkan Transfer Learning. Namun, Transfer Learning tetap menjadi pilihan yang baik apabila efisiensi waktu dan kemudahan implementasi menjadi prioritas utama.

Analisis Dataset

1. Apakah dataset yang digunakan cukup besar untuk melatih CNN From Scratch?

Ya, dataset CIFAR-10 dapat dikatakan cukup besar untuk melatih CNN From Scratch karena terdiri dari 50.000 data training dan 10.000 data testing. Jumlah data tersebut memungkinkan model mempelajari berbagai pola dan karakteristik citra sehingga menghasilkan performa yang cukup baik.

2. Apakah variasi gambar sudah cukup baik?

Ya, variasi gambar pada dataset CIFAR-10 cukup baik karena mencakup 10 kelas objek yang berbeda dengan berbagai posisi, ukuran, dan kondisi objek. Variasi ini membantu model belajar mengenali karakteristik setiap kelas secara lebih efektif.

3. Apakah terdapat ketidakseimbangan data?

Tidak. Dataset CIFAR-10 memiliki distribusi data yang relatif seimbang, di mana setiap kelas memiliki jumlah gambar yang hampir sama. Dengan demikian, risiko model menjadi bias terhadap kelas tertentu dapat diminimalkan.

4. Apakah gambar memiliki noise, background kompleks, atau variasi pencahayaan?

Ya. Beberapa gambar pada CIFAR-10 memiliki background yang kompleks, objek yang berukuran kecil, serta variasi pencahayaan dan sudut pengambilan gambar. Kondisi ini membuat proses klasifikasi menjadi lebih menantang dan mengharuskan model mempelajari fitur yang lebih beragam.

5. Bagaimana kualitas dataset memengaruhi hasil CNN dan Transfer Learning?

Kualitas dataset sangat memengaruhi performa model. Dataset yang memiliki jumlah data cukup, distribusi kelas yang seimbang, dan variasi gambar yang beragam membantu model memperoleh akurasi yang lebih baik. Pada penelitian ini, kualitas dataset yang baik memungkinkan CNN From Scratch mencapai akurasi testing sebesar 70,00%, sedangkan Transfer Learning mencapai akurasi testing sebesar 66,50%. Semakin baik kualitas dataset, semakin baik pula kemampuan model dalam melakukan generalisasi terhadap data baru.

Analisis Performa Model

1. Model mana yang menghasilkan performa terbaik?

Berdasarkan hasil eksperimen, CNN From Scratch menghasilkan performa terbaik dengan akurasi testing sebesar 70,00%, sedangkan

Transfer Learning menggunakan MobileNetV2 memperoleh akurasi testing sebesar 66,50%. Hal ini menunjukkan bahwa CNN From Scratch lebih mampu mempelajari karakteristik dataset yang digunakan pada penelitian ini.

2. Apakah akurasi tinggi selalu berarti model lebih baik?

Tidak. Akurasi yang tinggi tidak selalu menunjukkan bahwa model lebih baik. Selain akurasi, perlu diperhatikan faktor lain seperti nilai loss, kemampuan generalisasi, stabilitas model selama training, serta risiko terjadinya overfitting. Model yang memiliki akurasi tinggi pada data training tetapi rendah pada data testing belum tentu memiliki performa yang baik.

3. Apakah ada tanda-tanda overfitting?

Terdapat indikasi overfitting ringan pada CNN From Scratch karena akurasi training (77,55%) lebih tinggi dibandingkan akurasi validation (70,66%) dan testing (70,00%). Namun perbedaannya masih dalam batas yang wajar sehingga model masih dapat melakukan generalisasi dengan cukup baik terhadap data baru.

4. Model mana yang lebih stabil selama training?

Transfer Learning cenderung lebih stabil selama proses training. Hal ini terlihat dari nilai akurasi dan loss yang berubah secara lebih konsisten pada setiap epoch. Stabilitas tersebut diperoleh karena model memanfaatkan bobot pretrained yang telah dilatih sebelumnya sehingga proses pembelajaran menjadi lebih terarah.

5. Bagaimana hubungan antara jumlah data dan performa model?

Jumlah data memiliki pengaruh yang sangat penting terhadap performa model. Semakin

banyak data yang tersedia, semakin baik kemampuan model dalam mempelajari pola dan melakukan generalisasi. CNN From Scratch umumnya membutuhkan jumlah data yang lebih besar agar menghasilkan performa optimal, sedangkan Transfer Learning dapat tetap memberikan hasil yang baik meskipun jumlah data relatif terbatas karena memanfaatkan pengetahuan dari model pretrained.

3. Analisis Pemilihan Pendekatan

Berdasarkan hasil eksperimen, CNN From Scratch lebih cocok digunakan ketika tersedia dataset dalam jumlah besar, sumber daya komputasi yang memadai, dan dibutuhkan akurasi yang tinggi. Pada penelitian ini, CNN From Scratch memperoleh akurasi testing sebesar 70,00%, lebih tinggi dibandingkan Transfer Learning yang memperoleh 66,50%.

Sementara itu, Transfer Learning lebih sesuai digunakan ketika jumlah data terbatas, waktu pengembangan singkat, dan sumber daya komputasi terbatas. Selain lebih cepat dilatih, Transfer Learning juga memiliki risiko overfitting yang lebih rendah. Oleh karena itu, pemilihan metode harus disesuaikan dengan ukuran dataset, kebutuhan akurasi, ketersediaan komputasi, dan tujuan penggunaan model

Studi Kasus Pengambilan Keputusan

Skenario 1

Kasus: Sebuah klinik ingin membuat sistem klasifikasi citra medis, tetapi hanya memiliki 300 gambar.

Jawaban:

Saya akan memilih Transfer Learning. Alasannya karena jumlah data yang tersedia

sangat sedikit sehingga CNN From Scratch berisiko mengalami *overfitting*. Transfer Learning memanfaatkan model yang telah dilatih sebelumnya pada dataset besar sehingga mampu menghasilkan performa yang lebih baik meskipun data yang tersedia terbatas. Selain itu, waktu pelatihan juga menjadi lebih cepat dibandingkan melatih model dari awal.

Skenario 2

Kasus: Sebuah perusahaan memiliki 1 juta gambar produk internal dengan karakteristik sangat berbeda dari dataset umum seperti ImageNet.

Jawaban:

Dalam kondisi ini, CNN From Scratch masih sangat relevan. Jumlah data yang sangat besar memungkinkan model mempelajari karakteristik dataset secara langsung tanpa bergantung pada fitur yang telah dipelajari dari ImageNet. Karena karakteristik data berbeda dengan dataset umum, model yang dilatih dari awal dapat menghasilkan representasi fitur yang lebih sesuai dengan kebutuhan perusahaan.

Skenario 3

Kasus: Anda diminta membuat prototipe klasifikasi gambar dalam waktu dua hari. Dataset hanya 500 gambar.

Jawaban:

Pendekatan yang paling rasional adalah Transfer Learning. Dengan jumlah data yang terbatas dan waktu pengembangan yang singkat, Transfer Learning dapat menghasilkan model dengan performa yang cukup baik tanpa memerlukan proses pelatihan yang lama. Model pretrained seperti MobileNetV2 dapat langsung digunakan

sebagai dasar sehingga proses pembuatan prototipe menjadi lebih efisien.

Skenario 4

Kasus: Anda memiliki dataset besar, GPU memadai, dan ingin membuat model yang sangat spesifik untuk domain tertentu.

Jawaban:

Transfer Learning tidak selalu menjadi keharusan dalam kondisi ini. Dengan dataset yang besar dan sumber daya komputasi yang memadai, CNN From Scratch dapat menjadi pilihan yang tepat karena model dapat mempelajari karakteristik khusus dari domain tersebut secara lebih mendalam. Namun, Transfer Learning tetap dapat digunakan sebagai titik awal untuk mempercepat proses pelatihan. Pemilihan metode bergantung pada tujuan penelitian dan kebutuhan performa model.

VI. KESIMPULAN

Berdasarkan hasil eksperimen, CNN From Scratch memperoleh akurasi testing sebesar 70,00%, sedangkan Transfer Learning menggunakan MobileNetV2 memperoleh akurasi sebesar 66,50%. Hasil ini menunjukkan bahwa CNN From Scratch memberikan performa yang lebih baik pada dataset yang digunakan.

Meskipun demikian, Transfer Learning memiliki keunggulan dalam hal kecepatan pelatihan dan kemudahan implementasi. Oleh karena itu, pemilihan metode harus disesuaikan dengan jumlah data, sumber daya komputasi, dan kebutuhan aplikasi yang dikembangkan.

VII. REFLEKSI PRIBADI

1. Apa tantangan terbesar saat mengerjakan tugas ini?

Tantangan terbesar dalam mengerjakan tugas ini adalah memahami proses pelatihan model deep learning serta melakukan pengaturan parameter agar model dapat berjalan dengan baik dan menghasilkan akurasi yang optimal.

2. Bagian mana yang paling sulit: CNN From Scratch atau Transfer Learning? Mengapa?

Menurut saya, CNN From Scratch lebih sulit karena seluruh model harus dibangun dan dilatih dari awal. Selain itu, proses pelatihannya membutuhkan waktu yang lebih lama dibandingkan Transfer Learning yang sudah memanfaatkan model pretrained.

3. Apa perbedaan paling terasa antara melatih model dari awal dan menggunakan pretrained model?

Perbedaan yang paling terasa adalah waktu pelatihan dan kemudahan implementasi. CNN From Scratch membutuhkan proses pelatihan yang lebih lama, sedangkan Transfer Learning dapat memberikan hasil yang cukup baik dalam waktu yang lebih singkat karena memanfaatkan pengetahuan dari model yang telah dilatih sebelumnya.

4. Jika tugas ini digunakan untuk kasus nyata, pendekatan mana yang akan Anda pilih?

Saya akan memilih Transfer Learning apabila jumlah data terbatas dan waktu pengembangan singkat. Namun, jika tersedia dataset yang besar dan sumber daya komputasi yang memadai, saya akan mempertimbangkan CNN From Scratch untuk mendapatkan model yang lebih spesifik terhadap kebutuhan aplikasi.

5. Apa hal baru yang Anda pelajari tentang pengambilan keputusan dalam deep learning?

Saya belajar bahwa pemilihan model deep learning tidak hanya berdasarkan akurasi yang tinggi, tetapi juga harus mempertimbangkan jumlah data, waktu pelatihan, sumber daya komputasi, serta kebutuhan dari permasalahan yang akan diselesaikan. Dengan demikian, pemilihan metode yang tepat dapat menghasilkan solusi yang lebih efektif dan efisien.